PROYECTO: ACA N° 2 - APRENDIZAJE AUTOMÁTICO

Modelado con Redes Neuronales Artificiales (CNN, RNN, Transformers) y Despliegue Interactivo en Streamlit

Corporación Unificada Nacional de Educación Superior (CUN) | Escuela de Ingeniería | Especialización en Inteligencia Artificial
Asignatura: Aprendizaje Automático | Docente: Hamilton Rivera Flor

📌 SECCIÓN 1: ¿De qué se trata el proyecto? (Propósito y Pregunta Orientadora)

🎯 Objetivo General

Desarrollar e implementar una solución avanzada mediante modelos de redes neuronales artificiales (convolucionales, recurrentes o arquitecturas Transformer, pudiendo adaptar modelos preentrenados desde Hugging Face o entrenar arquitecturas profundas a la medida) aplicada a un problema del mundo real (en salud, educación o ventas), integrando preprocesamiento, ajuste fino/entrenamiento, evaluación y despliegue funcional en una interfaz gráfica interactiva con Streamlit.

❓ Pregunta Orientadora / Situación Problema

¿Cómo aprovechar las arquitecturas de redes neuronales (CNN, RNN, Transformers) o modelos de Hugging Face para extraer patrones complejos en datos de salud, educación o ventas, optimizando el rendimiento predictivo y permitiendo su interacción práctica a través de una interfaz en Streamlit?

📊 SECCIÓN 2: Catálogo de Proyectos y Temáticas (3 Pilares)

🩺 Proyecto 1: Salud

- **Enfoque:** Clasificación diagnóstica, análisis de bioseñales/imágenes o procesamiento de lenguaje clínico.
- **Modalidades y Arquitecturas:**
    - Visión por Computador con CNNs o Vision Transformers (ViT) para imágenes radiológicas o dermatológicas.

    - Redes Recurrentes (LSTM/GRU) o Transformers para señales biomédicas temporales o reportes clínicos.
    - Adaptación de modelos de Hugging Face especializados en bio-salud.
- **Datasets sugeridos:**
    - Chest X-Ray Images (Pneumonia)
    - Skin Cancer MNIST: HAM10000
    - UCI Heart Disease / UCI Breast Cancer Wisconsin

🎓 Proyecto 2: Educación

- **Enfoque:** Predicción del rendimiento escolar, analítica de trayectorias formativas y análisis textual de retroalimentación.
- **Modalidades y Arquitecturas:**
    - Modelos Transformers (BERT, RoBERTa o similares de Hugging Face) para clasificación de comentarios de estudiantes o tickets académicos.
    - Redes Neuronales Recurrentes (LSTM/GRU) o Perceptrones Multicapa (MLP) profundos para predicción temporal de deserción académica.
- **Datasets sugeridos:**
    - UCI Predict Students Dropout and Academic Success
    - UCI Student Performance Dataset
    - Students Performance in Exams Dataset
    - xAPI-Edu-Data

🛒 Proyecto 3: Ventas

- **Enfoque:** Procesamiento de lenguaje natural en reseñas, predicción secuencial de demanda o recomendación profunda.
- **Modalidades y Arquitecturas:**
    - Transformers de Hugging Face para análisis de sentimiento, extracción de aspectos y clasificación de opiniones en comercio electrónico.
    - Redes Recurrentes (LSTM/GRU) o modelos temporales basados en atención para pronóstico de series de tiempo de ventas.
- **Datasets sugeridos:**
    - Consumer Reviews of Amazon Products
    - Brazilian E-Commerce Public Dataset by Olist
    - Sales Forecasting - Retail Superstore
    - UCI Online Retail Dataset

🛠️ SECCIÓN 3: Ruta de Aprendizaje y Flujo Metodológico

PASO 1	PASO 2	PASO 3	PASO 4	PASO 5
Exploración y Gestión SQL EDA, comprensión y base de datos SQL	**Preparación y Pipeline** Aumento de datos, tokenización y/o secuencias	**Modelado Neuronal** CNN, RNN, Transformers o Hugging Face	**Evaluación y Métricas** Loss, Accuracy, F1-Score y/o matriz de confusión	**Despliegue Streamlit** App gráfica interactiva y funcional

- **PASO 1: Exploración y Gestión de Datos**
  Comprensión del problema, análisis exploratorio (EDA) y tokenización/procesamiento según la modalidad (texto, imagen y/o tabla). Incluye la gestión del dataset mediante una base de datos SQL (como SQLite, DuckDB u otra de su elección) para el almacenamiento, inserción y consulta eficiente de datos.
- **PASO 2: Preparación y Pipeline**
  Acondicionamiento del dataset, aumento de datos (data augmentation), generación de datos con IA, tokenización o ingeniería de secuencias, cualquier tarea requerida para el procesamiento y paso de los datos al modelo.
- **PASO 3: Modelado con Redes Neuronales**
  Construcción, entrenamiento o fine-tuning de arquitecturas neuronales (CNN, RNN, Transformers) o adaptación desde Hugging Face.
- **PASO 4: Evaluación y Métricas**
  Evaluación cuantitativa del desempeño (Loss, Accuracy, F1-Score, Matriz de Confusión, curvas de entrenamiento/validación).
- **PASO 5: Despliegue en Streamlit**
  Integración de los pesos/pipeline del modelo neuronal en una aplicación interactiva y funcional en Streamlit.

📦 SECCIÓN 4: Entregables Oficiales del Proyecto

📓 1. Notebook de Jupyter (.ipynb)

Código reproducible, documentado y modular con todo el flujo: preprocesamiento, definición o descarga/ajuste de la red neuronal, entrenamiento, curvas de aprendizaje y evaluación.

📄 2. Póster tipo Infografía

Póster sintético y visual en formato infografía que debe contener: Nombres de integrantes, objetivo general, descripción de la situación problema / pregunta orientadora, explicar el dataset seleccionado, resumen del flujo metodológico (diagrama y/o imagen), arquitectura de red neuronal empleada (CNN, RNN, Transformer o modelo Hugging Face adaptado), principales métricas y resultados del

modelo de ML, y una vista previa de la aplicación gráfica (streamlit), Conclusiones y enlace de la aplicación desarrollada y del video.

💻 3. App Interactiva Streamlit

Código de la interfaz (app.py), scripts auxiliares, dependencias (requirements.txt) e instrucciones para cargar el modelo (o enlazar el repositorio/pipeline de Hugging Face).

📽️ 4. Video de Sustentación (3 a 5 min)

Exposición sintética del equipo: problema, arquitectura de red seleccionada, métricas obtenidas y demostración en vivo de la aplicación en Streamlit y del póster.

📈 SECCIÓN 5: Rúbrica de Evaluación y Ponderaciones

Peso	Criterio	Descripción de Desempeño
20%	1. Calidad de Datos y Preprocesamiento	Coherencia en la preparación, tokenización o preprocesamiento adecuado para la arquitectura neuronal seleccionada.
20%	2. Arquitectura de Red Neuronal	Justificación técnica, implementación idónea y entrenamiento/fine-tuning del modelo neuronal (CNN, RNN, Transformer o Hugging Face).
15%	3. Interfaz Streamlit	Interfaz interactiva, funcional y conectada adecuadamente con el pipeline/modelo de Deep Learning.
15%	4. Métricas de Evaluación	Análisis cuantitativo riguroso de métricas de desempeño, curvas de pérdida/exactitud e interpretación de resultados.

Peso	Criterio	Descripción de Desempeño
15%	5. Póster tipo Infografía PDF	Cumplimiento de normas APA 7, claridad del poster y reproducibilidad.
15%	6. Sustentación en Video	Claridad en la exposición, precisión conceptual sobre la red neuronal y cumplimiento del tiempo estipulado (3 a 5 min).

📚 Referencias Bibliográficas

- Aljarah, I. (2016). xAPI-Edu-Data (Student Academic Performance) [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/aljarah/xAPI-Edu-Data
- Cortez, P. (2014). UCI Student Performance Dataset [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/320/student+performance
- Datafiniti. (2019). Consumer Reviews of Amazon Products [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/datafiniti/consumer-reviews-of-amazon-products
- Elkharoua, R. (2024). Students Performance in Exams Dataset [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/rabieelkharoua/students-performance-dataset
- Janosi, A., Steinbrunn, R., Pfisterer, M., & Detrano, R. (1988). UCI Heart Disease Dataset [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/45/heart+disease
- Luque, G. (2021). Sales Forecasting - Retail Superstore [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/rohitsahoo/sales-forecasting
- Martins, M. V., Real, M. B., Machado, J., & Becker, A. (2021). UCI Predict Students Dropout and Academic Success [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success
- Mooney, P. (2018). Chest X-Ray Images (Pneumonia) [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia

- Olist. (2018). Brazilian E-Commerce Public Dataset by Olist [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce
- Tschandl, P. (2018). Skin Cancer MNIST: HAM10000 [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/kmader/skin-cancer-mnist-ham10000
- Chen, D. (2015). UCI Online Retail Dataset [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/352/online+retail
- Wolberg, W., Street, N., & Mangasarian, O. (1995). UCI Breast Cancer Wisconsin (Diagnostic) [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic
- Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., ... & Rush, A. M. (2020). Transformers: State-of-the-art natural language processing. In Proceedings of the 2020 conference on empirical methods in natural language processing: system demonstrations (pp. 38-45).